

CADAP-1: Diseño, Validación y Evaluación de un Corpus Acústico del Aimara Puneño para Modelos ASR Fundacionales

Omar Condori Pachauri 1
Universidad Peruana Union
Escuela Profesional de Ingeniería de Sistemas
Lima, Peru
omarcondori@upeu.edu.pe

Abstract

Foundational models for Automatic Speech Recognition (ASR) systematically fail in zero-shot scenarios when processing low-resource, highly agglutinative languages like Peruvian Aymara. The scarcity of acoustic data with technical standardization and deep morphological annotation limits the adaptation of these networks, leading to the loss of critical semantic information. To address this data engineering gap, we present CADAP-1, a structured dialectal acoustic corpus developed through a rigorous pipeline using data from six native speakers in Puno, comprising 110 utterances (18.8 minutes) of high-fidelity audio (16 kHz, SNR > 48 dB). The dataset features a four-layer computational segmentation in ELAN to isolate critical evidential suffixes (-wa, -tayna, -chi) and employs a strict per-speaker partitioning (4/1/1 split) to prevent data leakage and memorization. To validate the corpus in an extreme few-shot scenario, a baseline was established using the Whisper-small model. Initial zero-shot evaluation yielded a Word Error Rate (WER) of 436.80% due to severe hallucinations. However, applying parameter-efficient fine-tuning via Low-Rank Adaptation (LoRA) reduced the WER to 95.20% and the Character Error Rate (CER) to 29.71%, demonstrating that the model successfully captured the phonetic acoustics despite the agglutinative complexity. CADAP-1 stands as a high-fidelity, morphologically-aware acoustic resource, natively compatible with the HuggingFace ecosystem, providing a robust foundation for efficient model adaptation and future research in Andean speech technologies.

CCS Concepts

• **Computing methodologies** → Speech recognition; Natural language processing; Neural networks; • **General and reference** → Evaluation; • **Information systems** → Language resources.

Keywords

Ingeniería de datos, Corpus acústico, Aimara, Reconocimiento automático del habla (ASR), Lenguas aglutinantes, Prevención de fuga de datos, Modelos fundacionales, LoRA

1 Introduction

Los modelos fundacionales de Reconocimiento Automático del Habla (ASR), como Whisper y Wav2Vec 2.0, han transformado el procesamiento del lenguaje natural al alcanzar niveles de precisión cercanos al humano en condiciones ricas en datos. Sin embargo, su desempeño colapsa estrepitosamente en escenarios *zero-shot* cuando se enfrentan a lenguas de bajos recursos y de naturaleza polisintética y aglutinante [10, 11, 15], como es el caso del aimara

peruano [12]. A diferencia de los idiomas hegemónicos, el aimara carece de la infraestructura de datos masivos necesaria para adaptar estas arquitecturas [2]. Al intentar solucionar esto mediante un ajuste fino (*fine-tuning*) completo, se incurre en costos computacionales prohibitivos [17] o se provoca el fenómeno de “olvido catastrófico” (*catastrophic forgetting*), donde el modelo pierde su capacidad de procesar idiomas previamente aprendidos [14]. El principal vacío tecnológico actual no es únicamente la falta de audio, sino la ausencia de arquitecturas de datos estandarizadas y anotadas morfológicamente. En lenguas aglutinantes como el aimara, que cuenta con una intrincada estructura de más de 140 sufijos [7], un error en la decodificación de un morfema —especialmente los marcadores de evidencialidad (-wa, -tayna, -chi)— altera drásticamente el significado proposicional del enunciado, con graves consecuencias en aplicaciones del mundo real. Los corpus andinos existentes han estado históricamente enfocados en tareas de traducción de texto a texto [2], y aquellos orientados al habla (como los aplicados al quechua) carecen de controles rigurosos de calidad acústica o de la segmentación computacional necesaria para el entrenamiento efectivo de redes neuronales [12]. Asimismo, para que un modelo fundacional pueda aprender el idioma sin sobreajustarse o memorizar la voz del hablante, se requieren conjuntos de datos con diseños experimentales estrictos que prevengan la fuga de datos (*data leakage*) [9]. Para resolver esta brecha de ingeniería de datos, este artículo presenta CADAP-1 (Corpus Acústico Dialectal del Aimara Peruano), un recurso lingüístico diseñado como corpus de alta fidelidad para la ingesta directa en modelos ASR fundacionales. Las contribuciones principales de este trabajo son:

Contribution. Las contribuciones principales de este trabajo son:

- (1) **Arquitectura de Datos y Estandarización:** Diseño de un pipeline de captura validado con 6 hablantes nativos de la región de Puno, procesado bajo estrictos umbrales de calidad (formato WAV a 16 kHz, canal mono, 16-bit, SNR > 48 dB). Esta estandarización acústica (WAV a 16 kHz) responde a los requerimientos de entrada nativos de arquitecturas como Whisper, que exigen frecuencias específicas y formatos sin compresión para extraer espectrogramas precisos [11, 15]. Asimismo, el control riguroso de la relación señal-ruido (SNR) es un requerimiento indispensable documentado para evitar que modelos fundacionales como Whisper y Wav2Vec 2.0 degraden críticamente su precisión de transcripción frente al ruido ambiental, un problema severo en entornos de bajos recursos [9].
- (2) **Anotación Computacional de Evidencialidad:** Aislamiento sistemático de sufijos morfológicos críticos mediante capas computacionales en ELAN. Esta segmentación guiada por

morfología es una estrategia computacional crucial documentada para habilitar el entrenamiento efectivo de redes neuronales, permitiendo a los modelos acústicos capturar la alta complejidad aglutinante de lenguas andinas como el aimara [2, 12].

- (3) **Diseño Experimental Libre de Fugas:** Estructuración de la metadata y de los vectores de audio bajo los estándares de compatibilidad nativa de HuggingFace, una práctica documentada para la ingesta eficiente y el modelado flexible en entornos de bajos recursos [11]. Asimismo, se aplicó una partición de conjuntos (**aproximadamente 66/17/17**) exclusivamente por hablante (**4/1/1**) para prevenir la fuga de datos y el sobreajuste a perfiles vocales específicos. Este esquema garantiza la generalización del modelo frente a la variabilidad individual, siendo una estrategia validada para la evaluación confiable de ASR en lenguas minoritarias [9].

2 Related Work

Históricamente, la investigación computacional en lenguas andinas de bajos recursos se ha concentrado en el procesamiento de texto, dejando un vacío significativo en el desarrollo de recursos acústicos. Por un lado, trabajos recientes han demostrado la viabilidad de entrenar modelos neuronales (Seq2Seq y Transformers) para la traducción automática del español al aimara utilizando corpus paralelos de texto, implementando con éxito enfoques de aprendizaje con pocos datos (*few-shot*) para superar la falta de recursos [2, 5]. En el ámbito del procesamiento del habla, se introdujeron evaluaciones de arquitecturas en cascada para la traducción de voz del quechua al español apoyándose en el corpus acústico Siminchik, evidenciando que los enfoques modulares superan a los de extremo a extremo en estos escenarios [12]. No obstante, bases de datos de acceso abierto como Common Voice poseen una cantidad estadísticamente insuficiente de horas de audio verificadas para el aimara. Por otro lado, aunque existen corpus multilingües masivos como el *CMU Wilderness* que documentan más de 16 horas de audio en aimara derivadas de textos bíblicos [1], estos recursos no logran representar el habla natural, dialectal y cotidiana. Además, tal como lo señalan las investigaciones respecto a las plataformas de recolección remota o basada en la web [16], estos corpus colaborativos suelen sacrificar la calidad de la señal acústica y carecen por completo de la segmentación temporal y anotación morfológica profundas necesarias para capturar la evidencialidad de la lengua. La Tabla 1 sintetiza esta brecha tecnológica, evidenciando la superioridad estructural de CADAP-1 frente a los recursos existentes.

Table 1: Comparación de corpus acústicos en lenguas andinas.

Corpus	Idioma	Habla- tes	Horas	Anotac. Morfol.	Control SNR	Compat. HuggingF.
Siminchik [4]	Quechua chanka y collao	No decl.	~97h	No (texto)	No estricto	No (Parcial)
Quechua Collao[13]	Quechua collao	7	~15h 15m	No (Dimensional: val., Act., Dom)	No estricto	No (No decl.I)
CMU Wilderness [1]	Aimara y Quechua Surboliviano	Varios	Aimara (16h 19m) Quechua (>47h)	No (texto bíblico)	No	Parcial
Common Voice [3]	Aimara	Varios	<5h	No (texto)	No	Parcial
CADAP-1 (Nues.)	Aimara (Puno)	6	18.8 m	Sí (Eviden.)	Sí (>48 dB)	Sí (Nativa)

Para resolver desafíos similares en otras lenguas aglutinantes de bajos recursos, la literatura reciente enfatiza la necesidad de *pipelines* rigurosos de ingeniería de datos. Estudios en idioma kazajo han demostrado que el ajuste fino de modelos fundacionales como Whisper reduce drásticamente las tasas de error frente a los enfoques *zero-shot*, requiriendo previamente una estandarización técnica rigurosa de la señal acústica [11, 15]. Asimismo, en el ámbito de la adaptación de dominio para ASR, trabajos como el de Qian et al. [14] validan el uso de la Adaptación de Bajo Rango (LoRA) sobre el modelo Whisper, demostrando que es posible integrar un idioma no soportado previamente entrenando una fracción mínima de los parámetros y mitigando eficazmente el fenómeno de "olvido catastrófico" (*catastrophic forgetting*). En contraste con los trabajos anteriores, CADAP-1 se distingue por integrar un diseño experimental enfocado puramente en la arquitectura del dato para Inteligencia Artificial. Mientras que los corpus andinos previos se han limitado a la transcripción ortográfica [2], CADAP-1 introduce una segmentación computacional mediante capas en ELAN para aislar explícitamente los sufijos de evidencialidad (*-wa*, *-tayna*, *-chi*). Además, supera las deficiencias de los repositorios colaborativos al implementar una partición estricta por hablante, estableciendo así un corpus acústico-lingüístico nativamente compatible con el ecosistema de HuggingFace.

3 Methodology

El desarrollo de CADAP-1 sigue un pipeline riguroso de ingeniería de datos, estructurado metodológicamente para garantizar la viabilidad del entrenamiento y la convergencia de modelos neuronales acústicos.

3.1 Arquitectura y Captura de Datos

Se diseñó un protocolo de elicitación enfocado en la cobertura morfológica, capturando 110 archivos de audio (18.8 minutos de duración neta) provenientes de 6 hablantes nativos de la región de Puno. La recolección se ejecutó utilizando dispositivos móviles (smartphones) y grabadoras digitales en entornos naturales y controlados. El uso de teléfonos inteligentes ha sido validado en la literatura reciente como una alternativa tecnológica confiable frente

a los equipos de grabación profesional, permitiendo la recolección fidedigna de corpus acústicos en lenguas minorizadas sin perder calidad espectral [8, 15]. La muestra mantuvo un balance representativo de género (distribución de 59 grabaciones masculinas y 51 femeninas). Los enunciados fueron seleccionados estratégicamente para asegurar la presencia de marcadores de evidencialidad (evidencia directa *-wa*, reportada *-tayna*, e inferencial *-chi*), así como oraciones cotidianas diseñadas para capturar flexiones nominales y casos espaciales frecuentes (el posesivo *-ja*, el pluralizador *-naka*, el direccional *-ru* y el locativo *-na*).

Este tamaño de muestra, estratificada geográficamente y por género, es consistente con los protocolos metodológicos recientes para la creación de corpus acústicos en lenguas aglutinantes de bajos recursos. Dicho enfoque garantiza la variabilidad fonética inicial necesaria para evitar el sesgo de memorización del modelo, sin incurrir en costos de recolección inmanejables [15]. Finalmente, la captura de audio se estandarizó bajo los requerimientos exactos de ingesta para arquitecturas fundacionales como Whisper: formato WAV sin compresión, frecuencia de muestreo de 16 kHz, canal mono y profundidad de 16-bit. El uso de estos parámetros acústicos (16 kHz y canal mono) constituye un estándar validado en la literatura reciente para la extracción robusta de características en modelos de aprendizaje profundo [8]. Esta rigurosidad técnica previene la degradación espectral de la señal y asegura la compatibilidad nativa con los extractores de características del modelo [15, 17].

3.2 Procesamiento Computacional y Anotación en ELAN

El preprocesamiento acústico se automatizó mediante scripts en Python (v3.10), utilizando las librerías `librosa` (v0.10) y `noisereducer` para la normalización de volumen y reducción de ruido, un enfoque estandarizado en la literatura reciente para el procesamiento de corpus en entornos de bajos recursos [15]. Como se ha evidenciado en el desarrollo de datasets primarios para lenguas minoritarias, la segmentación precisa del habla en oraciones y unidades discretas constituye un requisito ineludible para construir modelos ASR robustos [8]. Por ello, para la estructuración lingüística, se empleó la herramienta ELAN, implementando cuatro capas independientes: (1) transcripción verbatim, (2) traducción al español, (3) morfosintaxis, y (4) aislamiento de sufijos de evidencialidad. Esta segmentación guiada por morfología es fundamental para el procesamiento de lenguas andinas altamente aglutinantes [11, 12]. Para garantizar la validez lingüística y la reproducibilidad, el corpus fue sometido a una revisión cruzada inter-anotador del 10% a cargo de lingüistas y traductores bilingües certificados (aimara-español), una práctica de auditoría humana fundamental para asegurar la inteligibilidad y naturalidad en corpus construidos desde cero [16?]. Esta anotación multicapa convierte el corpus en un “Gold Standard” optimizado para entrenar modelos bajo paradigmas de Aprendizaje Multitarea (Multi-Task Learning), una estrategia que permite co-optimizar tareas auxiliares y mejorar significativamente la precisión general del sistema [6].

3.3 Prevención de Fugas de Datos (Data Leakage)

Para evitar que las redes neuronales memoricen los patrones vocales de los participantes y prevenir el sobreajuste a perfiles específicos




Figure 1: Interfaz de anotación en ELAN para CADAP-1. Se observa la alineación temporal a nivel de milisegundos y las cuatro capas computacionales independientes, destacando el aislamiento del sufijo de evidencialidad en la última pista.

[9]. La partición del dataset se realizó exclusivamente a nivel de hablante. Se asignaron 4 hablantes al conjunto de entrenamiento (aprox. 66%), 1 hablante a validación (17%) y 1 hablante a prueba (17%), un esquema validado para garantizar la generalización en lenguas de bajos recursos y evaluar en condición *zero-shot*. [9]. Finalmente, los metadatos resultantes se estructuraron en formato tabular (CSV) con una jerarquía de directorios nativamente compatible con el ecosistema de HuggingFace, asegurando su ingesta directa y eficiente [11].

4 Experiments and Results

4.1 Validación Acústica y Estructural del Dataset

La evaluación de calidad de CADAP-1 se realizó mediante criterios instrumentales objetivos, un paso crítico en la construcción de corpus para evitar que el ruido de fondo y las distorsiones acústicas degraden el desempeño de los modelos [11]. A nivel de ingeniería de señales, se aplicó un filtro estricto estableciendo un umbral mínimo de Relación Señal-Ruido (SNR) de 15 dB, descartando cualquier dato acústicamente irrecuperable. Esta práctica metodológica está documentada como necesaria para asegurar la inteligibilidad de la señal y la convergencia de redes neuronales profundas [9, 11]. El análisis instrumental de CADAP-1 arrojó resultados excepcionales, logrando una SNR media de 59.41 dB, con un mínimo de 48.69 dB, superando ampliamente el umbral de calidad exigido. La Tabla 2 resume las métricas de validación alcanzadas por el dataset final, garantizando 18.8 minutos de audio (110 archivos) de alta fidelidad, estandarizados y limpios para su uso en aprendizaje de tipo Few-Shot.

Table 2: Resultados de Validación del Corpus CADAP-1.

Criterio de Validación	Umbral Definido	Resultado CADAP-1
Cobertura de evidencialidad	≥ 30 ej. por tipo	30 ej. por sufijo (-wa / -tayna / -chi)
Cobertura de flexión nominal	Casos espaciales y plurales	40 oraciones cotidianas (-ja, -naka, -ru, -na)
Calidad acústica (SNR)	> 48 dB	Archivos < 48 dB descartados (Media de retención: 59.41 dB)
Frecuencia de muestreo y formato	16 kHz, mono, 16-bit, WAV	Verificado en los 110 archivos (sin compresión)
Consistencia de anotación	Verificación cruzada Kappa de Cohen ($\kappa > 0.80$)	Revisión del 10% inter-anotador completada ($\kappa = 0.94$)
Prevención de fuga de datos	Partición estricta por identidad de hablante	División 4/1/1 (Train / Val / Test)

4.2 Evaluación de Línea Base (Baseline)

Para demostrar la viabilidad computacional de CADAP-1 frente a arquitecturas del estado del arte, se estableció una evaluación de línea base (baseline) sobre el conjunto de prueba de 3 hablantes. Se expuso el corpus al modelo fundacional Whisper-small en condición zero-shot, registrando las Tasas de Error de Palabra (WER) y de Carácter (CER) iniciales. Evaluar el modelo bajo estas condiciones es una práctica estándar documentada para cuantificar la degradación del reconocimiento acústico frente a lenguas no vistas durante el preentrenamiento [11]. Como era previsible, el modelo base colapsó al intentar decodificar el aimara, produciendo alucinaciones textuales en español que dispararon el error a un WER de 436.80% y un CER de 202.56%, lo que establece el límite de error a superar. Para resolver esta deficiencia, se implementó un ajuste fino paramétricamente eficiente mediante LoRA (Adaptación de Bajo Rango), el cual es el método estándar actual para escalar de manera práctica el entrenamiento de modelos fundacionales mediante la descomposición de matrices y la reducción drástica de parámetros entrenables [18], siendo a su vez una estrategia validada para optimizar el rendimiento de Whisper en entornos de bajos recursos [11]. El modelo adaptado logró una mejora absoluta, reduciendo el WER a 95.20% y el CER a 29.71%. Un análisis crítico de esta discrepancia métrica revela que, si bien el sistema penaliza la palabra completa (WER) debido a la estricta ortografía de las lenguas aglutinantes, la IA logra transcribir el aimara con una precisión fonética por caracteres cercana al 70%. Algunas predicciones capturaron la acústica de forma casi exacta; por ejemplo, el modelo transcribió fonéticamente Argentina, Perú, Bolivia...” frente a la referencia normativa Arjintina, Pirü, Wuliwya...”. Esto demuestra empíricamente que la calidad de la señal de CADAP-1 permite al modelo aprender y decodificar correctamente los fonemas de la lengua. El código fuente y los scripts de evaluación de este estudio están disponibles públicamente en: <https://github.com/Omar-Condori/AYMA-ARUX>.

5 Discussion and Limitations

Los resultados de la validación demuestran que el pipeline de ingeniería de datos implementado para CADAP-1 logra estandarizar exitosamente la señal acústica del aimara peruano, cumpliendo con

los umbrales exigidos ($\text{SNR} > 15$ dB) para el entrenamiento robusto de redes neuronales [9]. A diferencia de corpus andinos previos que se limitan a la transcripción plana [2], la principal fortaleza de este dataset radica en su capa de anotación morfológica en ELAN, la cual aísla computacionalmente los sufijos de evidencialidad (-wa, -tayna, -chi). Esta estrategia es crucial para procesar lenguas altamente aglutinantes [12]. Esto, sumado a la partición estricta por hablante estructurada para HuggingFace [11], mitiga eficazmente la fuga de datos (data leakage) y proporciona un “Gold Standard” listo para la ingesta en modelos fundacionales [9].

No obstante, este trabajo presenta ciertas limitaciones que deben considerarse. En primer lugar, debido al tamaño del corpus y la partición por hablante, el conjunto de prueba (Test Set) está conformado únicamente por 1 individuo. Esto implica que las futuras evaluaciones de modelos podrían ser temporalmente sensibles a la variabilidad acústica o disfonías particulares de dicho hablante, limitando la generalización [9]. En segundo lugar, aunque 18.8 minutos de audio limpio (110 archivos) representan un avance significativo para el aimara y habilitan el aprendizaje *Few-Shot*, sigue siendo un escenario de muy bajos recursos que hace inviable un entrenamiento desde cero (from scratch) o un ajuste fino completo (full fine-tuning) [17] sin incurrir en el riesgo de olvido catastrófico (catastrophic forgetting) [14]. Finalmente, la representatividad dialectal está delimitada a las provincias de Ilave y Huancané (Puno), por lo que el rendimiento del modelo podría degradarse frente a dialectos no vistos del aimara central o boliviano, un desafío recurrente en la evaluación cruzada de corpus acústicos [9, 15].

6 Conclusion

Este artículo introduce CADAP-1, el primer corpus acústico-lingüístico del aimara peruano diseñado con rigor de ingeniería de datos, el cual aporta 110 archivos de audio (18.8 minutos) de alta calidad con anotación explícita de evidencialidad y prevención nativa de fugas de datos (data leakage) [9]. Este trabajo demostró la viabilidad de la ingesta de este dataset en el modelo fundacional Whisper-small utilizando Adaptación de Bajo Rango (LoRA, $r=16$) [14, 17], logrando un aprendizaje *Few-Shot* con el fin de evaluar y mitigar la propagación de errores en una arquitectura en cascada para la traducción de voz a voz en escenarios de bajos recursos [6, 12]. Como trabajo futuro, la investigación se enfocará en escalar la recolección del corpus a 20 hablantes nativos, aplicar el ajuste fino sobre la arquitectura de mayor capacidad Whisper large-v3, e integrar el modelo ASR resultante en el pipeline bidireccional completo AYMA-ARUX (ASR-MT-TTS) empleando NLLB-200.

References

- [1] Oliver Adams, Matthew Wiesner, Shinji Watanabe, and David Yarowsky. 2019. Massively Multilingual Adversarial Speech Recognition. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, Minneapolis, Minnesota, 96–108. doi:10.18653/v1/N19-1009
- [2] Honorio Apaza Alanoca. 2025. *Modelos neuronales de traducción automática para la lengua nativa aimara*. Tesis de Maestría. Universidad Nacional de San Agustín de Arequipa. <https://hdl.handle.net/20.500.12773/20396>
- [3] Rosana Ardila, Megan Branson, Kelly Davis, Michael Henretty, Michael Kohler, Josh Meyer, Reuben Morais, Lindsay Saunders, Francis M. Tyers, and Gregor Weber. 2020. Common Voice: A Massively-Multilingual Speech Corpus. In *Proceedings of the 12th Language Resources and Evaluation Conference (LREC 2020)*. 4218–4222. <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85095513677>

- [4] Ronald Cardenas, Rodolfo Zevallos, Reynaldo Baquerizo, and Luis Camacho. 2018. Siminchik: A Speech Corpus for Preservation of Southern Quechua. In *ISI-NLP 2*. 21.
- [5] Nat Gillin and Brian Gummibaerhausen. 2023. Few-shot Spanish-Aymara Machine Translation Using English-Aymara Lexicon. In *Proceedings of the Annual Meeting of the Association for Computational Linguistics*. 168–172.
- [6] Mahendra Gupta, Maitreyee Dutta, and Chandresh Kumar Maurya. 2025. Direct Speech-to-Speech Neural Machine Translation: A Survey. *Speech Communication* 175 (2025), 103317. doi:10.1016/j.specom.2025.103317
- [7] Felipe Huayhua Pari. 2017. Normas para el buen uso de la ortografía aimara. *Lengua y Sociedad* (2017). <http://revista.letras.unmsm.edu.pe/index.php/ls/article/view/428>
- [8] Umar Adam Ibrahim, Moussa Mahamat Boukar, and Muhammed Aliyu Suleiman. 2022. Development of Hausa Dataset: A Baseline for Speech Recognition. *Data in Brief* 40 (2022), 107820. doi:10.1016/j.dib.2022.107820
- [9] Jafar, Athul Wazithah Tb Mar, Rosary Iriany, Firman Aziz, and Norma Nasir. 2025. Fine-Tuning Whisper Model for Mandar Speech Recognition: Approach and Performance Evaluation. *Journal of Applied Engineering and Technological Science* 7, 1 (2025), 261–273. doi:10.37385/jaets.v7i1.7170
- [10] Bauyrzhan Kairatuly and Madina Mansurova. 2026. When Data Is Scarce: Training a Kazakh Speech Language Model from Discrete Units. *Applied Sciences* 16, 4 (2026). doi:10.3390/app16041773
- [11] Aidana Karibayeva, Vladislav Karyukin, Balzhan Abduali, and Dina Amirova. 2025. Speech Recognition and Synthesis Models and Platforms for the Kazakh Language. *Information (Switzerland)* 16, 10 (2025). doi:10.3390/info16100879
- [12] John E. Ortega, Rodolfo Zevallos, and William Chen. 2023. QUESPA Submission for the IWSLT 2023 Dialect and Low-resource Speech Translation Tasks. In *20th International Conference on Spoken Language Translation, IWSLT 2023 – Proceedings of the Conference*. 261–268.
- [13] Rosa Y. G. Paccotacya-Yanque, Candy A. Huanca-Anquise, Judith Escalante-Calquina, Wilber R. Ramos-Lovón, and Álvaro E. Cuno-Parari. 2022. A Speech Corpus of Quechua Collao for Automatic Dimensional Emotion Recognition. *Scientific Data* 9, 1 (2022). doi:10.1038/s41597-022-01855-9
- [14] Mengjie Qian, Siyuan Tang, Rao Ma, Kate M. Knill, and Mark J.F. Gales. 2024. Learn and Don't Forget: Adding a New Language to ASR Foundation Models. In *Proceedings of the Annual Conference of the International Speech Communication Association, INTERSPEECH*. 2544–2548. doi:10.21437/Interspeech.2024-1045
- [15] Diana Rakhimova, Zhansaya Duisenbekkyzy, and Esref Adali. 2025. Investigation of ASR Models for Low-Resource Kazakh Child Speech: Corpus Development, Model Adaptation, and Evaluation. *Applied Sciences (Switzerland)* 15, 16 (2025). doi:10.3390/app15168989
- [16] Agha Ali Raza, Awais Athar, Shan Randhawa, Zain Tariq, Muhammad Bilal Saleem, Haris Bin Zia, Umar Saif, and Roni Rosenfeld. 2018. Rapid Collection of Spontaneous Speech Corpora Using Telephonic Community Forums. In *Proceedings of the Annual Conference of the International Speech Communication Association, INTERSPEECH*. 1021–1025. doi:10.21437/Interspeech.2018-1139
- [17] Huan Wang, Jie Bin, Chunyan Gou, Lian Yang, Baolin Hou, and Mingwei Qin. 2025. Low-Resource Speech Recognition by Fine-Tuning Whisper with Optuna-LoRA. *Applied Sciences (Switzerland)* 15, 24 (2025). doi:10.3390/app152413090
- [18] Mengyao Zhu and Phuc Huu Nguyen. 2026. A Survey of LoRA Algorithm Variations for Language Models. *Lecture Notes in Computer Science* 15836 (2026), 275–290. doi:10.1007/978-3-031-97141-9_19